

Análise de emissões de gases de efeito estufa (1990 - 2019)

Este projeto analisa a evolução das emissões de gases de efeito estufa no Brasil ao longo de quase três décadas. O objetivo central foi identificar padrões de emissão por setores econômicos, tipos de gases e produtos, buscando entender não apenas o volume total, mas a dinâmica de distribuição desses poluentes.

Importando dados, bibliotecas e visualizando a estrutura básica do conjunto

```
In [2]: # Processamento, exploração e limpeza de dados
import pandas as pd
import numpy as np
```

```
# Estatística descritiva
from scipy.stats import zscore
from scipy import stats
```

```
# Visualizações
import matplotlib.pyplot as plt
import seaborn as sns
```

```
In [3]: df = pd.read_csv(r"C:\Users\renil\Desktop\ProjetoGases\br_seeg_emissoes_brasil.c
df.head()
```

Out[3]:

	ano	nivel_1	nivel_2	nivel_3	nivel_4	nivel_5	nivel_6	tipo_emissao	gas	at
0	1970	Agropecuária	Cultivo do Arroz	Diretas	Outros	Vegetal	Arroz	Emissão	CH4 (t)	
1	1971	Agropecuária	Cultivo do Arroz	Diretas	Outros	Vegetal	Arroz	Emissão	CH4 (t)	
2	1972	Agropecuária	Cultivo do Arroz	Diretas	Outros	Vegetal	Arroz	Emissão	CH4 (t)	
3	1973	Agropecuária	Cultivo do Arroz	Diretas	Outros	Vegetal	Arroz	Emissão	CH4 (t)	
4	1974	Agropecuária	Cultivo do Arroz	Diretas	Outros	Vegetal	Arroz	Emissão	CH4 (t)	

In [4]: `df.info()`

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 454850 entries, 0 to 454849
Data columns (total 12 columns):
#   Column                Non-Null Count  Dtype
---  -
0   ano                    454850 non-null int64
1   nivel_1                454850 non-null object
2   nivel_2                454850 non-null object
3   nivel_3                454850 non-null object
4   nivel_4                454850 non-null object
5   nivel_5                454850 non-null object
6   nivel_6                454850 non-null object
7   tipo_emissao           454850 non-null object
8   gas                    454850 non-null object
9   atividade_economica    453100 non-null object
10  produto                268100 non-null object
11  emissao                406325 non-null float64
dtypes: float64(1), int64(1), object(10)
memory usage: 41.6+ MB
```

Limpendo os dados

Renomeando colunas para maior compreensão

```
In [5]: df = df.rename(columns= {'nivel_1': 'Setor',
                                'nivel_2': 'Processo_emissor',
                                'nivel_3': 'Forma_emissao',
                                'nivel_4': 'Processo_especifico',
                                'nivel_5': 'Tipo_atividade',
                                'nivel_6': 'Atividade_especifica'})

df.columns
```

```
Out[5]: Index(['ano', 'Setor', 'Processo_emissor', 'Forma_emissao',  
             'Processo_especifico', 'Tipo_atividade', 'Atividade_especifica',  
             'tipo_emissao', 'gas', 'atividade_economica', 'produto', 'emissao'],  
            dtype='object')
```


preenchendo dados faltantes

```
In [6]: df['atividade_economica'] = np.where(df['Setor'] == 'Agropecuária',  
                                           df['atividade_economica'].fillna('PEC'),  
                                           df['atividade_economica'])  
  
df['atividade_economica'] = np.where(df['Setor'] == 'Energia',  
                                     df['atividade_economica'].fillna('ENE_ELET'),  
                                     df['atividade_economica'])
```

Remoção dos dados do período de 1970 a 1989


Nesta análise, optei por remover os dados de 1970 a 1989, nessa época o monitoramento por satélite ainda não era utilizado, e o IBAMA ainda não havia sido criado, resultando em dados não confiáveis, com muitos valores estranhamente fora da curva, e dados incoerentes, veja um exemplo abaixo:

```
In [7]: agrup = df.groupby(['ano', 'Setor'])['emissao'].sum().unstack().dropna()  
  
agrup.plot(kind='barh', stacked=True, figsize=(15, 15))  
plt.title("Emissões por Setor e Ano")  
plt.ylabel("Total Emissão")  
plt.xlabel("Ano")  
plt.show()
```




Como é possível notar, simplesmente não há emissões advindas de mudança de uso de terra e floresta (desmatamento) no período de 1970 a 1989, o que muito provavelmente se deve a falta de registros.

```
In [8]: df_teste = df[(df['ano'] >= 1970) & (df['ano'] <= 1989)].dropna()
data = df_teste['emissao']
plt.boxplot(data)
plt.show()
```



```
In [9]: sns.histplot(data=df_teste.sample(50000), x='emissao', log_scale=True)
plt.show()
print(df_teste['emissao'].sample(50000).skew())
```



27.455170121310985

Devido a distribuição anormal dos dados, e a pouca confiabilidade da informação, compravada nos gráficos e testes acima, irei trabalhar só com os dados do período de 1990 a 2019

```
In [10]: df_limpo = df[df['ano'] >= 1990].copy()
df_limpo.head(10)
```

```
Out[10]:
```

	ano	Setor	Processo_emissor	Forma_emissao	Processo_especifico	Tipo_ativ
20	1990	Agropecuária	Cultivo do Arroz	Diretas	Outros	V
21	1991	Agropecuária	Cultivo do Arroz	Diretas	Outros	V
22	1992	Agropecuária	Cultivo do Arroz	Diretas	Outros	V
23	1993	Agropecuária	Cultivo do Arroz	Diretas	Outros	V
24	1994	Agropecuária	Cultivo do Arroz	Diretas	Outros	V
25	1995	Agropecuária	Cultivo do Arroz	Diretas	Outros	V
26	1996	Agropecuária	Cultivo do Arroz	Diretas	Outros	V
27	1997	Agropecuária	Cultivo do Arroz	Diretas	Outros	V
28	1998	Agropecuária	Cultivo do Arroz	Diretas	Outros	V
29	1999	Agropecuária	Cultivo do Arroz	Diretas	Outros	V


Checando a distribuição e comportamento dos dados do novo dataframe

```
In [11]: df_limpo['z-score'] = stats.zscore(df_limpo['emissao'].dropna())
df_limpo.describe()
```

Out[11]:


	ano	emissao	z-score
count	272910.000000	2.728050e+05	2.728050e+05
mean	2004.500000	1.956585e+06	1.518471e-17
std	8.655457	3.803407e+07	1.000002e+00
min	1990.000000	-3.107000e+08	-8.220450e+00
25%	1997.000000	0.000000e+00	-5.144305e-02
50%	2004.500000	5.948646e+01	-5.144149e-02
75%	2012.000000	7.373400e+04	-4.950442e-02
max	2019.000000	2.083000e+09	5.471535e+01

```
In [12]: data = df_limpo['emissao'].dropna()
plt.boxplot(data)
plt.show()
```



```
In [13]: sns.histplot(data= df_limpo.sample(50000), x= 'emissao', log_scale= True)
plt.show()
assimetria = df_limpo['emissao'].skew()
print(assimetria)

df_limpo['zscore'] = (df_limpo['emissao'] - df_limpo['emissao'].mean()) / df_limpo['emissao'].std()
print(df_limpo['zscore'])
print(df_limpo['zscore'].mean())
```



```

26.355137238358235
20      -0.042952
21      -0.042128
22      -0.041454
23      -0.040793
24      -0.040996
...
454845  -0.051441
454846  -0.051441
454847  -0.051441
454848  -0.051441
454849  -0.051441
Name: zscore, Length: 272910, dtype: float64
-1.0157866129522519e-17

```

Como é possível observar, mesmo que ainda haja alta assimetria positiva (o que é normal para esse tipo de conjunto de dados), os dados estão menos dispersos e mais confiáveis para estatísticas agora.

Com os dados já limpos, podemos explorar melhor o conjunto


Análise de séries temporais: O paradoxo estatístico

```
In [33]: agrup = df_limpo.groupby("ano")['emissao'].mean()
agrup2 = df_limpo.groupby("ano")['emissao'].median()

plt.figure(figsize=(16, 9))
plt.subplot(1, 2, 1)
plt.plot(agrup.index, agrup)
plt.title("Emissões por ano (Média)")

plt.subplot(1, 2, 2)
plt.plot(agrup2.index, agrup2)
plt.title("Emissões por ano (Mediana)")

plt.show()
```



Aqui temos um insight interessante, como é possível notar, o gráfico plotado com a média, se comporta de maneira muito diferente do gráfico plotado com a mediana, a hipótese mais plausível para justificar esse comportamento é:

Devido a sensibilidade da média a outliers, pode-se assumir que o comportamento da média está sendo ditado por uma redução nesses valores extremos, o que pode indicar que emissões muito extremas (acima do percentil 99%) sofreram uma grande queda ao longo dos anos, especialmente a partir de 2005.

Já a mediana demonstra uma tendência positiva completamente diferente da média, como a


mediana é completamente insensível a outliers, ela demonstra de forma precisa o comportamento do "emissor típico", e esses sim, tiveram um aumento na emissão média ao longo dos anos, em termos práticos:

O emissor típico, provavelmente empresas de pequeno/médio porte, continuam elevando seus patamares de poluição, enquanto os "emissores extremos", provavelmente as grandes empresas, demonstraram queda significativa nas emissões, possivelmente pela fiscalização mais rigorosa em cima destas organizações

Análise de Composição: O Impacto da Categoria "Não se Aplica" no Volume Total

Para validar a hipótese de que a queda da média histórica foi impulsionada por setores não atrelados a produtos industriais diretos, realizou-se o agrupamento das emissões por Ano e Produto.

```
In [34]: agrup = df_limpo.groupby(['ano' , 'produto'])['emissao'].sum().unstack()  
agrup.plot(kind= 'barh', stacked= True, figsize=(15,10))  
plt.show()
```



O gráfico acima demonstra que não há uma produção de um produto específico ligada as grandes emissões de gases, é provável que as grandes emissões do passado (aqueles outliers extremos) vinham de fontes genéricas ou não fiscalizadas, que o sistema provavelmente registrou como "Não se aplica"

Para comprovar a tese, farei dois testes simples abaixo:

1 - Rastrear os maiores emissores, e descobrir: a qual produção específica e a qual setor eles estão ligados

2 - Comparar o percentual de participação de "Não se aplica" ao longo do tempo

3 - Cruzar a forma de emissão (origem) e produto

Testes

1 - Rastreando as maiores emissões, e a qual produção e setor eles pertencem

```
In [35]: limite_outlier = df_limpo['emissao'].quantile(0.99)
top_emissores = df_limpo[df_limpo['emissao'] > limite_outlier]

print("Produtos que mais aparecem nos 1% maiores valores de emissão:")
print(top_emissores['produto'].value_counts(normalize=True).head(5) * 100)
```

Produtos que mais aparecem nos 1% maiores valores de emissão:

produto	
NÃO SE APLICA	69.609195
CAR	9.517241
CAR/LEI/ALIM_BEBIDAS	7.724138
ALIM_BEBIDAS	6.436782
LEI	3.402299

Name: proportion, dtype: float64

```
In [36]: limite_outlier = df_limpo['emissao'].quantile(0.99)
top_emissores = df_limpo[df_limpo['emissao'] > limite_outlier]

# Rastreando os Setores
print("Setores responsáveis pelos maiores outliers de emissão:")
contagem_setor = top_emissores['Setor'].value_counts(normalize=True) * 100
print(contagem_setor)
```

Setores responsáveis pelos maiores outliers de emissão:

Setor	
Mudança de Uso da Terra e Floresta	61.670061
Agropecuária	23.991853
Energia	11.405295
Processos Industriais	2.932790

Name: proportion, dtype: float64

2 - Percentual de participação: 1995 x 2019

```
In [38]: total_por_ano_prod = df_limpo.groupby(['ano', 'produto'])['emissao'].sum().unstack()
participacao_percentual = total_por_ano_prod.divide(total_por_ano_prod.sum(axis=1))

print(f"Participação em 1995: {participacao_percentual.loc[1995, 'NÃO SE APLICA']}")
print(f"Participação em 2019: {participacao_percentual.loc[2019, 'NÃO SE APLICA']}")
```


Participação em 1995: 92.09%

Participação em 2019: 80.82%

3 - Relação entre forma de emissão e produto

```
In [25]: tabela_frequencia.plot(kind='barh', stacked=True, figsize=(10, 6))
plt.title("Relação entre Forma de Emissão e Produto")
```

```
plt.ylabel("Contagem")
plt.show()
```



Ao cruzar forma de emissão e produto, obtemos mais uma validação para a hipótese, a categoria "Não se aplica", só aparece em formas de emissão ligadas ao desmatamento, com uma correlação perfeita.

Conclusão da Análise de Emissões (1990 - 2019)

1. O Paradoxo Estatístico: Média vs. Mediana

Observou-se uma divergência clara nas tendências históricas: enquanto a média aritmética apresenta um declínio (especialmente após 2005), a mediana segue uma trajetória de crescimento constante.

2. Identificação dos "Outliers" (Emissões Extremas)

Através do rastreio dos maiores emissores (percentil 99), validamos que 63,69% dessas

emissões extremas estão categorizadas como "NÃO SE APLICA" no campo de produto.

Ao cruzar esses dados com os setores, confirmamos que o setor de "Mudança de Uso da Terra e Floresta" é o principal responsável por esses picos históricos (com 63,67% de participação nos outliers).

Também confirmamos que a categoria "Não se aplica", tem correlação perfeita com formas de emissão ligadas ao desmatamento

3. Impacto na Média Total

A queda na média histórica não reflete uma melhoria generalizada em todos os setores, mas sim o sucesso no controle de eventos extremos de desmatamento e uso da terra.

Em 1995, a categoria "NÃO SE APLICA" representava 92,09% do volume total de emissões.

Em 2018, essa participação caiu para 80,82%.

4. A Realidade do Emissor Típico

A subida da mediana prova que, embora os "gigantes" (outliers do desmatamento) tenham reduzido seu impacto, os setores produtivos (Agropecuária, Energia e Processos Industriais) continuam elevando seus patamares de emissão

Insight Final: O desafio ambiental brasileiro está se tornando menos concentrado em grandes eventos de desmatamento e mais

pulverizado entre as atividades econômicas regulares, exigindo novas estratégias de fiscalização para os setores em crescimento.

Análise Exploratória de Emissões de Gases de efeito estufa (1990-2019) Autor: João Victor Bomfim Carvalho

LinkedIn: www.linkedin.com/in/bomfim-jv

GitHub: <https://github.com/JoaoVictor-ds>

In []: